Tugas Take Home - Sesi 05 Advanced CNNs and Transfer Learning

Tugas Take-Home Sesi 05

Transfer Learning untuk Klasifikasi Citra dengan Data Terbatas

> ⓘ **Ringkasan Penugasan**
>
> - **Sifat Tugas:** Individu, *take-home*, berbasis implementasi praktikum (*hands-on*).
> - **Bobot Nilai:** 12,5% dari total komponen nilai tugas mata kuliah.
> - **Batas Waktu Pengumpulan:** 7 hari kalender (Senin, 12 Oktober 2026, pukul 23.59 WIB).
> - **Platform Komputasi:** Google Colab (alokasi runtime GPU T4 gratis sudah memadai).
> - **Luaran yang Dikumpulkan:**
>   1. Berkas Jupyter Notebook (`.ipynb`) yang dieksekusi lengkap beserta luaran selnya.
>   2. Dokumen laporan analisis (`.pdf` atau `.md`) format 3–5 halaman.
>   3. Berkas catatan metrik mentah (`.csv` atau `.json`).
> - **Kanal Pengumpulan:** Thread forum LMS kelas.
> - **Rujukan Materi:** Bahan tayang Sesi 05 — *Advanced CNNs and Transfer Learning* (Slide 5 s.d. 30).

---

1. Latar Belakang dan Konteks Masalah

Pada Sesi 05, kita telah membedah komponen penting yang memungkinkan arsitektur Convolutional Neural Networks (CNN) modern dilatih secara stabil dan berkinerja tinggi:

1. **Batch Normalization** (Slide 6–8) untuk stabilitas distribusi aktivasi dan percepatan konvergensi.
2. **Residual Connections / Skip Connections** (Slide 10–12) guna mengatasi degradasi performa pada jaringan yang sangat dalam.
3. **Transfer Learning dan Fine-Tuning** (Slide 14–18) untuk memanfaatkan representasi visual dari model *pretrained*.
4. **Data Augmentation** (Slide 20–22) sebagai mekanisme regularisasi penahan *overfitting*.

Sesi diakhiri dengan studi arsitektur modern seperti EfficientNet (Slide 24) serta panduan praktis pemilihan strategi adaptasi domain (Slide 27–29).

Tugas ini mensimulasikan studi kasus rekayasa praktis yang sangat lazim dihadapi praktisi *computer vision* di industri maupun riset terapan: membangun sistem klasifikasi citra berakurasi tinggi dengan keterbatasan data berlabel (*small-data regime*) dan anggaran komputasi minimal. Anda dituntut untuk merumuskan rekomendasi teknis berbasis bukti empiris eksperimen mandiri mengenai strategi mana yang paling optimal untuk diterapkan pada lingkungan produksi.

Fokus penyelidikan Anda berakar langsung pada dilema teknis di Slide 15 dan 16:

> *Kapan kita cukup membekukan representasi backbone (feature extraction), dan dalam kondisi apa penyesuaian bobot secara mendalam (fine-tuning) mutlak diperlukan?*

---

2. Tujuan dan Sasaran Tugas

Melalui tugas ini, mahasiswa diharapkan mampu:

1. Mengembangkan pipeline klasifikasi citra terstandarisasi berbasis PyTorch dan `torchvision`.
2. Mengevaluasi performa model secara komparatif melalui tiga paradigma: pelatihan dari nol (*from scratch*), ekstraksi fitur (*feature extraction*), dan *progressive fine-tuning*.
3. Menganalisis peran uji kontrol *data augmentation* dalam menekan *generalization gap* pada data terbatas.
4. Mengeksplorasi trade-off efisiensi komputasi terhadap performa pada arsitektur modern (misal: ResNet-18 vs. EfficientNet-B0 / MobileNetV3).
5. Menyusun laporan analisis komparatif dan analisis kesalahan (*failure analysis*) yang kritis dan dapat dipertanggungjawabkan secara ilmiah.

---

3. Bagian A: Analisis Konseptual (Bobot: 20%)

Jawab kelima pertanyaan berikut secara ringkas, padat, dan terstruktur (100–150 kata per nomor). Cantumkan rujukan nomor slide yang relevan serta sitasi literatur ilmiah pendukung jika merujuk sumber eksternal.

1. **Efek Regularisasi pada Batch Normalization (Slide 6–8)**
   Slide 8 menyebutkan bahwa Batch Normalization *"acts like mild regularization"* dan *"often eliminates the need for Dropout"*.
   - Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi tersebut.

- Uraikan kondisi atau skenario spesifik ketika asumsi "menghilangkan Dropout" ini tidak lagi berlaku atau justru dapat memicu instabilitas pelatihan.

2. **Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)**
   Mengapa penambahan kedalaman lapisan pada *plain CNN* (tanpa sambungan residual) justru menurunkan akurasi pelatihan (*degradation problem*), padahal secara teoritis representasi model yang lebih dalam minimal dapat menyamai model dangkal via fungsi identitas (*identity mapping*)?
   - Jelaskan bagaimana *skip connection* mengubah formulasi aliran gradien saat propagasi balik (*backpropagation*).
   - Hubungkan mekanisme tersebut dengan mitigasi fenomena *vanishing gradient* yang telah dibahas pada Sesi 02.
3. **Feature Extraction vs. Fine-Tuning (Slide 14–16)**
   Bandingkan pendekatan *Feature Extraction* (membekukan *backbone*) dengan *Fine-Tuning* (membuka sebagian atau seluruh lapisan) ditinjau dari empat dimensi:
   - Jumlah parameter yang diperbarui (*trainable parameters*).
   - Kebutuhan volume data latih.
   - Beban komputasi dan memori per *epoch*.
   - Risiko rusaknya fitur representasi bawaan (*destructive gradient updates*).
     Sintesiskan kriteria praktis kapan masing-masing pendekatan paling tepat dipilih.
4. **Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)**
   - Jelaskan pertimbangan metodologis mengapa pipeline *data augmentation* hanya diaktifkan pada *train set* dan harus dinonaktifkan pada *validation/test set*.
   - Berikan satu contoh teknik transformasi citra yang **tidak layak digunakan** untuk klasifikasi ras hewan peliharaan (*pet breeds*), dan jelaskan argumentasi ketidaklayakannya berdasarkan invariansi semantik label.
5. **Mitigasi Catastrophic Forgetting (Slide 28–29)**
   Slide 28 mengingatkan potensi terjadinya *catastrophic forgetting* apabila proses adaptasi model berlangsung terlalu agresif.
   - Uraikan bagaimana fenomena hilangnya representasi bawaan tersebut terjadi.
   - Jelaskan dua strategi mitigasi konkret (misalnya *differential learning rate*, *gradual unfreezing*, atau *linear warmup*) beserta alasan teoritis mengapa strategi tersebut efektif.

---

4. Bagian B: Eksperimen Praktik (Bobot: 40%)

4.1 Pemilihan Dataset

Mahasiswa dapat memilih salah satu opsi dataset berikut:

- **Opsi Utama (Sangat Disarankan): Oxford-IIIT Pet**
  Tersedia langsung melalui `torchvision.datasets.OxfordIIITPet` tanpa autentikasi

pihak ketiga. Dataset ini memiliki 37 kelas ras kucing dan anjing dengan ~200 citra per kelas.
Aturan Khusus: Ambil subset **10 kelas** (disarankan 5 ras kucing dan 5 ras anjing) guna merefleksikan skenario data terbatas (~2.000 citra). Lakukan pembagian data internal secara stratified: 70% data latih (*train*), 15% data validasi (*validation*), dan 15% data uji (*test*).

- **Opsi Alternatif: CIFAR-10**
  Dapat digunakan untuk mengkaji fenomena ketidaksesuaian resolusi bawaan (32x32 piksel) terhadap model *pretrained* ImageNet (resolusi standar 224x224 piksel). Kaitkan implikasi teknisnya dengan materi Slide 28.
- **Opsi Mandiri: Dataset Domain Tertentu (Kaggle/Eksternal)**
  Diperkenankan dengan mengajukan konfirmasi kepada dosen terlebih dahulu. Syarat: skala data maksimal 5.000 citra dan minimal 2 kelas klasifikasi.

4.2 Standarisasi Protokol Eksperimen

Agar perbandingan performa antar kondisi valid dan terkontrol secara ilmiah, terapkan protokol eksperimen yang seragam:

- **Arsitektur Utama:** ResNet-18 (`torchvision.models.resnet18`).
- **Bobot Pretrained:** `ResNet18_Weights.IMAGENET1K_V1` .
- **Dimensi Input:** 224 × 224 piksel dengan normalisasi standar ImageNet (`mean=[0.485, 0.456, 0.406]` , `std=[0.229, 0.224, 0.225]`).
- **Hyperparameter Dasar:** Batch size 32, optimizer `AdamW` , fungsi objektif `CrossEntropyLoss` .
- **Kriteria Berhenti:** *Early stopping* memonitor *validation loss* dengan nilai *patience* 3 s.d. 5 epoch.
- **Reproduksibilitas:** Tentukan *random seed* tetap (misal `seed = 42`) untuk PyTorch, NumPy, dan Python *built-in* guna memastikan keterulangan hasil.
- **Pencatatan Metrik:** Setiap eksperimen wajib mencatat:
  - Jumlah parameter yang dapat dilatih (*trainable parameters*).
  - *Learning rate* per kelompok parameter.
  - Jumlah epoch hingga konvergen.
  - Durasi pelatihan total.
  - Nilai akhir akurasi validasi dan **Macro F1-Score** pada data uji (*test set*).

4.3 Matriks Kondisi Eksperimen

Lakukan pengujian terhadap kondisi-kondisi berikut:

Kode	Kondisi Eksperimen	Deskripsi Teknis
B1	**Baseline from Scratch**	Latih ResNet-18 dari inisialisasi acak (`weights=None`) pada 10 kelas. Kondisi ini menjadi tolok ukur batas bawah (*baseline*) efektivitas representasi pretrained.
B2	**Feature Extraction**	Gunakan ResNet-18 *pretrained*, bekukan seluruh lapisan *backbone* (`requires_grad = False`), ganti layer `model.fc` dengan linear head baru (`nn.Linear(512, 10)`), dan latih hanya bagian *classifier head*.
B3	**Progressive Fine-Tuning**	Mulai dari model *pretrained*, buka pembekuan (*unfreeze*) blok residual terakhir (`layer4`) dan lapisan `fc` . Terapkan *differential learning rate* (misalnya: `lr = 1e-4` untuk `layer4` dan `lr = 1e-3` untuk `fc`).
B4	**Uji Kontrol Data Augmentation**	Pilih salah satu kondisi (B2 atau B3), lalu jalankan dalam dua skenario terpisah: 1. *Tanpa augmentasi* (hanya Resize/Crop dan Normalisasi). 2. *Dengan augmentasi* (Resize/Crop, Random Horizontal Flip, Random Rotation 15°, dan Color Jitter). Evaluasi selisih akurasi dan tingkat *overfitting*-nya.
B5	**Arsitektur Pembanding** *(Bonus)*	Jalankan konfigurasi terbaik Anda pada arsitektur modern berorientasi efisiensi seperti EfficientNet-B0 atau MobileNetV3-Small. Bandingkan trade-off performa (Macro F1), jumlah parameter, dan durasi komputasinya (rujuk Slide 24).

4.4 Kerangka Kode Awal (Starter Code)

Gunakan potongan kode berikut sebagai acuan dasar arsitektur model dan pipeline transformasi. Sesuaikan dan lengkapi dalam notebook Anda:

```
import torch
import torch.nn as nn
from torchvision import models, transforms

# 1. Inisialisasi Model & Ekstraksi Bobot Pretrained
weights = models.ResNet18_Weights.IMAGENET1K_V1
model = models.resnet18(weights=weights)

# 2. Konfigurasi B2: Feature Extraction (Bekukan Backbone)
for param in model.parameters():
    param.requires_grad = False

# Ganti classifier head untuk 10 kelas
num_features = model.fc.in_features
model.fc = nn.Linear(num_features, 10)
```

```
# 3. Konfigurasi B3: Unfreeze Blok Residual Terakhir (layer4)
for param in model.layer4.parameters():
    param.requires_grad = True

# Optimasi dengan Differential Learning Rate
optimizer = torch.optim.AdamW([
    {"params": model.layer4.parameters(), "lr": 1e-4},
    {"params": model.fc.parameters(),     "lr": 1e-3},
], weight_decay=1e-2)

# 4. Pipeline Transformasi Data
# Data latih: menerapkan augmentasi aktif
train_transforms = transforms.Compose([
    transforms.Resize(256),
    transforms.RandomResizedCrop(224, scale=(0.8, 1.0)),
    transforms.RandomHorizontalFlip(p=0.5),
    transforms.RandomRotation(degrees=15),
    transforms.ColorJitter(brightness=0.2, contrast=0.2),
    transforms.ToTensor(),
    transforms.Normalize(mean=weights.transforms().mean,
std=weights.transforms().std),
])

# Data validasi/uji: hanya deterministik tanpa distorsi
eval_transforms = weights.transforms()

# Verifikasi parameter yang dapat dilatih
trainable_params = sum(p.numel() for p in model.parameters() if
p.requires_grad)
total_params = sum(p.numel() for p in model.parameters())
print(f"Trainable Parameters: {trainable_params:,} / {total_params:,}")
```

Tips Implementasi

Pastikan Anda selalu memverifikasi jumlah parameter yang aktif sebelum `optimizer` dibentuk. Bila seluruh *backbone* dibekukan, `trainable_params` pada ResNet-18 seharusnya hanya berkisar 5.130 parameter (hanya layer `fc`).

---

5. Bagian C: Laporan dan Analisis (Bobot: 35%)

Susun laporan teknis komprehensif format 3 s.d. 5 halaman. Laporan ditulis dalam Bahasa Indonesia yang formal dan lugas, dengan tetap mempertahankan istilah teknis machine learning dalam Bahasa Inggris untuk menghindari distorsi makna.

Laporan wajib mencakup komponen-komponen berikut:

- **C1. Tabel Konsolidasi dan Visualisasi Pembelajaran**
  Sajikan tabel komparatif menyeluruh yang merangkum kondisi B1 hingga B5 (meliputi: strategi, jumlah *trainable parameters*, *learning rate*, *epoch* konvergen, waktu pelatihan, akurasi validasi, dan Macro F1 test). Lengkapi dengan grafik komparatif kurva *training loss* vs. *validation loss* untuk kondisi B1, B2, dan B3.
- **C2. Pembahasan Analisis Komparatif**
  Analisis fenomena empiris yang muncul dari data Anda dengan mengaitkannya pada konsep Slide 10–12, 16, 20, dan 28:
  1. Mengapa terjadi disparitas performa yang tajam antara pelatihan dari nol (B1) dengan paradigma transfer learning (B2 & B3)?
  2. Bagaimana trade-off performa vs. stabilitas antara *feature extraction* murni dan *fine-tuning* bertahap pada volume data terbatas yang Anda miliki?
  3. Sejauh mana peran augmentasi (B4) dalam meredam *overfitting* (perhatikan celah selisih akurasi data latih terhadap data validasi)?
- **C3. Failure Analysis (Analisis Kasus Misklasifikasi)**
  Tampilkan 5 s.d. 8 sampel citra dari *test set* yang salah diprediksi oleh model terbaik Anda. Untuk setiap sampel, sertakan:
  - Citra input bersangkutan.
  - Label aktual (*ground truth*).
  - Prediksi model beserta probabilitas keyakinan (*confidence score*).
  - Hipotesis penyebab kesalahan (misalnya: ambiguitas visual antar ras, sudut pengambilan ekstrem, oklusi, pencahayaan buruk, atau bias latar belakang).
- **C4. Rekomendasi Rekayasa dan Batasan Eksperimen**
  Berikan rekomendasi praktis bagi tim rekayasa industri: strategi pelatihan mana yang paling optimal untuk skenario data terbatas, lengkap dengan kondisi berlakunya (*operational constraints*). Sebutkan secara jujur limitasi dari studi Anda (misalnya: pengujian berbasis *single seed*, keterbatasan jumlah kelas, atau anggaran komputasi).
- **C5. Eksplorasi Tambahan (Nilai Tambah / Opsional)**
  Lakukan visualisasi representasi fitur (seperti feature map aktivasi atau Grad-CAM) pada blok `layer4` sebelum dan sesudah proses fine-tuning. Analisis bagaimana representasi visual bergeser setelah model disesuaikan dengan domain data spesifik (merujuk *best practice* Slide 29).

---

6. Luaran dan Ketentuan Pengumpulan

6.1 Berkas yang Wajib Dikumpulkan

1. **Jupyter Notebook (`.ipynb`):** Kode bersih, modular, dapat direproduksi dari awal hingga akhir (*run all cells* tanpa eror), dengan seluruh visualisasi dan luaran sel

tersimpan.
2. **Dokumen Laporan (`.pdf` atau `.md`):** Format 3–5 halaman yang memuat visualisasi, tabel metrik, dan analisis mendalam.
3. **Log Hasil Mentah (`.csv` atau `.json`):** Berkas log metrik pelatihan sebagai bukti integritas data hasil eksekusi.
4. **Tautan repositori GitHub** yang rapi dilengkapi `README.md` dan `requirements.txt`.

6.2 Format dan Tata Cara Pengumpulan

- Tugas bersifat **individual**.
- Arsipkan seluruh berkas luaran ke dalam satu file ZIP dengan format penamaan: `Tugas05_<NIM>_<NamaMahasiswa>.zip`
- Kumpulkan melalui thread forum LMS mata kuliah dengan judul balasan yang sama: `Tugas05_<NIM>_<NamaMahasiswa>`.

---

7. Integritas Akademik dan Kebijakan Penggunaan AI (Bobot: 5%)

Integritas dan kejujuran ilmiah merupakan nilai mendasar dalam perkuliahan ini:

1. **Pemahaman Mandiri:** Setiap mahasiswa wajib memahami secara mendalam setiap baris kode dan narasi yang dikumpulkan. Dosen berhak melakukan wawancara lisan singkat secara acak mengenai materi pengerjaan.
2. **Sitasi dan Atribusi:** Kode pustaka pihak ketiga, tutorial publik, atau referensi paper wajib dicantumkan sumbernya secara eksplisit.
3. **Kebijakan Pemanfaatan Asisten AI (Generative AI):**
   - Penggunaan model AI (seperti ChatGPT, Claude, GitHub Copilot, Gemini, dsb.) **diperbolehkan** sebagai alat bantu debugging kode, referensi sintaksis, atau klarifikasi pemahaman konsep.
   - Pemanfaatan AI tidak akan mengurangi nilai selama Anda transparan dan bertanggung jawab.
   - Jika Anda memanfaatkan AI, sertakan lampiran **"Pernyataan Penggunaan AI" (*AI Disclosure Statement*)** pada akhir laporan yang menjelaskan:
     - Nama model/alat AI yang digunakan.
     - Ruang lingkup bantuan AI pada tugas ini.
     - Cara Anda memverifikasi kebenaran keluaran AI tersebut secara mandiri.
   - Seluruh analisis, interpretasi hasil empiris, dan penarikan kesimpulan pada laporan **wajib ditulis secara mandiri**. Praktik plagiarisme, fabrikasi data, atau penyerahan kode/teks generik tanpa pemahaman akan mengakibatkan pembatalan nilai tugas.

---

8. Rubrik Penilaian

No	Kriteria Evaluasi	Bobot	Indikator Kinerja Utama	Capaian Pembelajaran (LO)
1	**Analisis Konseptual (Bagian A)**	20%	Ketepatan dan kedalaman penjelasan mekanisme BatchNorm, degradasi residual, perbandingan feature extraction vs. fine-tuning, prinsip augmentasi, dan mitigasi catastrophic forgetting. Rujukan nomor slide tepat.	LO3, LO4
2	**Kualitas Implementasi Pipeline (B1–B4)**	25%	Notebook dieksekusi *end-to-end* tanpa eror. Pembekuan dan pembukaan bobot layer dilakukan dengan benar. Augmentasi data diisolasi secara tepat pada data latih. Tidak terjadi kebocoran data (*data leakage*). Seed tercatat.	LO1, LO2
3	**Kelengkapan Matriks Eksperimen**	15%	Empat kondisi utama (B1–B4) terlaksana secara lengkap dan setara di bawah protokol eksperimen terstandar. Kondisi B5 (arsitektur pembanding) dieksekusi dengan baik sebagai nilai tambah.	LO1, LO2
4	**Kedalaman Analisis dan Pembahasan (Bagian C)**	25%	Tabel konsolidasi metrik tersaji lengkap, kurva pelatihan terbaca jelas, *failure analysis* memuat hipotesis teknis yang logis, rekomendasi rekayasa didukung data empiris dan memuat batasan operasional yang jelas.	LO3, LO4
5	**Struktur Laporan dan Reproduksibilitas**	10%	Sistematika dokumen rapi, visualisasi profesional, tata bahasa lugas dan baku, konfigurasi eksperimen terdokumentasi lengkap, serta sitasi referensi valid.	LO1, LO4

No	Kriteria Evaluasi	Bobot	Indikator Kinerja Utama	Capaian Pembelajaran (LO)
6	**Integritas Akademik dan Pernyataan AI**	5%	Transparansi pernyataan penggunaan AI, angka metrik pada laporan konsisten dengan log data mentah, dan mahasiswa menguasai materi tugasnya.	LO4
	Total Skor	**100%**		

> ⚠ **Catatan Penilaian Data Empiris**
>
> Seluruh klaim performa pada dokumen laporan harus bersumber dari berkas log mentah (`.csv` / `.json`) yang terlampir. Setiap kondisi eksperimen yang dilaporkan tanpa disertai data log pendukung hanya akan dinilai maksimal 50% dari bobot kriteria terkait, karena angka tanpa artefak verifikasi tidak dapat divalidasi.